

# Rapport sur la collecte et l'exploitation des données en langue soninké

18 février 2025

# 1 Collecte de données par scraping

Dans le cadre de notre projet, nous avons mis en place une méthode automatisée de collecte et de traitement de données à partir de ressources en ligne. L'objectif était de récupérer des fichiers PDF contenant des ressources culturelles en soninké, d'en extraire le contenu textuel et de le nettoyer afin de ne conserver que la partie rédigée en soninké, en éliminant les éléments en français ou en anglais.

## Méthodologie adoptée

Pour réaliser cette collecte, nous avons procédé en plusieurs étapes :

### 1. Identification et extraction des informations

Nous avons commencé par accéder à des pages web spécialisées, telles que le site [Asawan.org](http://Asawan.org), qui propose une sélection de livres et de ressources en soninké. Nous avons analysé la structure des pages pour identifier les éléments correspondant aux documents PDF (titres, tailles de fichier, et liens de téléchargement). Ces informations ont ensuite été centralisées dans un fichier de suivi (au format CSV).

### 2. Téléchargement et extraction des données

Pour chaque document identifié, nous avons automatisé le téléchargement du fichier PDF. Une fois le PDF récupéré, nous avons procédé à l'extraction du contenu textuel à partir de chaque page. Ce contenu brut a été sauvegardé dans un fichier texte, ce qui nous permet de disposer d'une version intégrale des données contenues dans le PDF.

### 3. Nettoyage et filtrage du contenu

Afin de ne conserver que le texte rédigé en soninké, nous avons appliqué un processus de nettoyage. Ce filtrage a permis d'éliminer les en-têtes, titres de leçons, numéros de page et tout autre élément indésirable (par exemple, les annotations en français ou en anglais). Le résultat obtenu est un fichier texte épuré, contenant uniquement le contenu en soninké.

## Organisation des fichiers

L'ensemble de ces opérations (téléchargement, extraction et nettoyage) a été automatisé et organisé dans un répertoire dédié, nommé « Histoire ». Dans ce dossier, nous retrouvons :

- Les fichiers PDF téléchargés,
- Un fichier CSV récapitulatif contenant les informations de chaque PDF (titre, taille, lien),
- Pour chaque PDF, un fichier texte brut avec le contenu extrait,
- Pour chaque PDF, une version nettoyée du texte (contenant uniquement le contenu en soninké).

## Accès aux données

Les fichiers générés grâce à ce processus de scraping sont centralisés et accessibles via le lien [Google Drive](#). Ce système de collecte et de traitement automatisé permet de mettre à jour régulièrement la base de données et de partager facilement les résultats avec l'ensemble des parties prenantes du projet.

## 2 Bibliographie des livres en soninké et ressources associées

### Ouvrages didactiques et méthodes linguistiques

- **Méthodes d'apprentissage :**

Par exemple, *Soninké : Apprendre les bases de la langue soninké* est une ressource référencée sur des sites tels que [Fnac](#) et [Amazon](#).

- **Autres ouvrages pratiques :**

Certains ouvrages peuvent être consultés via les portails suivants :

- [Soninkara](#)

- [Sooninke](#)

### Ressources en ligne pour accéder aux livres en soninké

- [Asawan.org](#) – Section Soninké

- [Soninkara.com](#)

- [Sooninke.com](#)

- [Gallica](#) – Recherche Soninké

## 3 Sociétés et associations pour la promotion de la langue Soninké

### Associations dédiées

- **Association pour la Promotion de la Langue et de la Culture Soninké (APS)**

L'APS, fondée en 1979, œuvre pour la préservation et la valorisation de la langue et des traditions soninké à travers divers événements culturels, ateliers et initiatives éducatives. Pour plus d'informations, consultez leur page sur [HelloAsso](#).

**Contact :**

Adresse : 30, Rue de Strasbourg, 93200 Saint-Denis, France

Téléphone : [+33 09 50 29 51 95](#)

Email : [soninkoaps@yahoo.fr](mailto:soninkoaps@yahoo.fr)

## 4 Conclusion

La collecte automatisée par scraping a permis de recueillir de manière efficace et rigoureuse un volume important de données en soninké, assurant ainsi une mise à jour régulière et une qualité optimale des fichiers. La diversité des ouvrages et des ressources numériques recensées enrichit la base de données et facilite l'accès aux supports culturels et pédagogiques. Par ailleurs, la collaboration avec des associations telles que l'APS renforce la promotion et la valorisation de la langue et de la culture soninké.